0129

LINC: Enabling Low-Resource In-network Classification and Incremental Model Update-关注在交换机上部署分类器所遇到的问题

问题

1. **硬件资源受限**：可编程交换机内存非常有限，且需保留资源给基础转发功能。现有方法（如决策树、随机森林）往往需要在模型复杂度和资源消耗之间做权衡，导致性能下降。
2. **增量更新困难**：网络流量分布会随时间变化，需要更新模型。
    - 传统重训练方法耗时且中断业务。
    - 少样本学习（Few-Shot Learning）难题：新出现的流量类别往往只有少量标注数据，直接重训练会导致模型对旧数据过拟合或对新数据识别率低。

解决方法

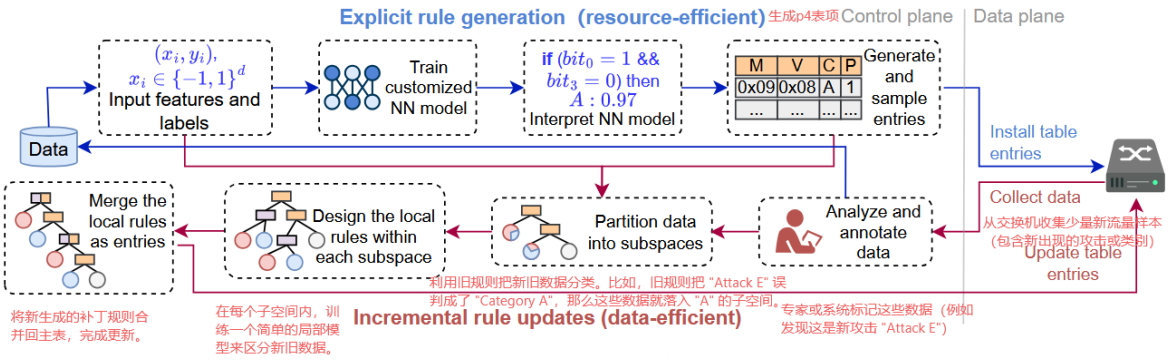

Fig. 2: Overview of LINC framework

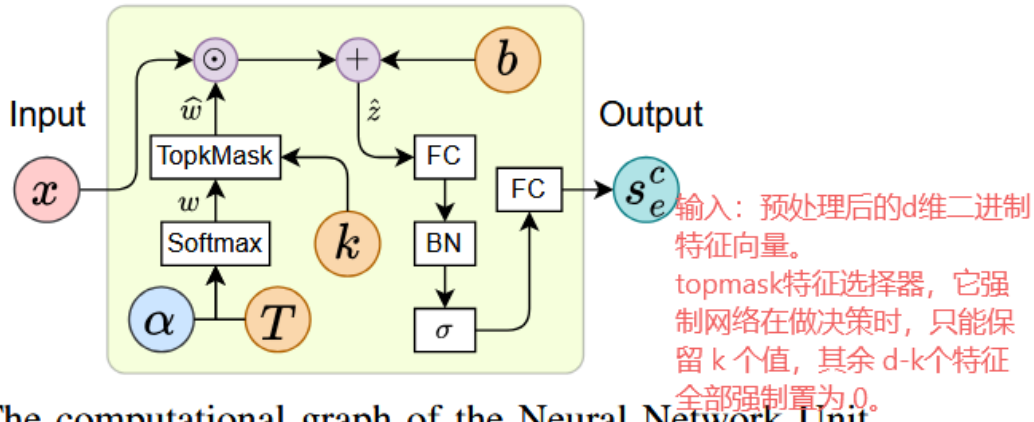

Fig. 3: The computational graph of the Neural Network Unit (NNU).

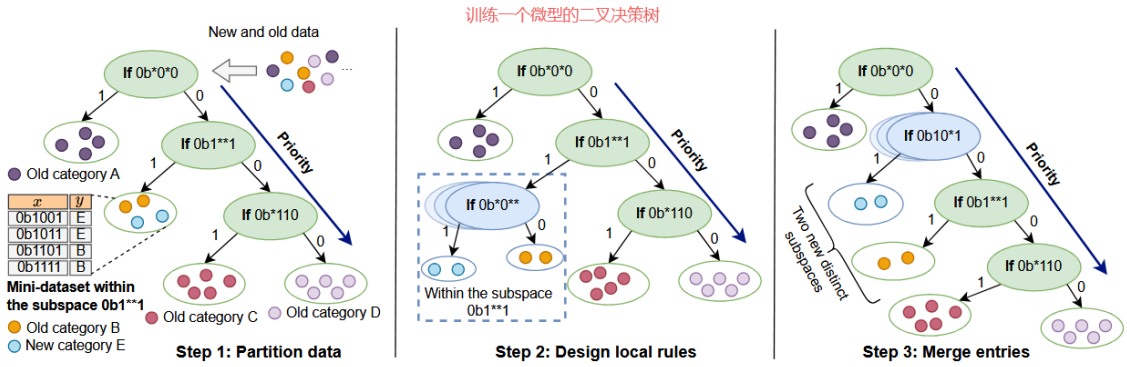

Fig. 4: The flowchart of incremental rule updates. The blue ellipses in the second tree represent multiple newly generated entries, and this figure only displays two decision branches of a blue entry for convenience.

数据集

1. **UNIV1**
   - **内容**：用于预测流的大小，具体是区分“大流”（Elephants）和“小流”（Mice）。
   - **来源**：校园网流量数据。
2. **ISCX**
   - **内容**：用于识别不同的应用层流量类型。
   - **类别**：Email, Chat, Streaming, File Transfer, VoIP, P2P 等。
3. **UNSW-NB15**
   - **内容**：用于入侵检测，区分正常流量和恶意流量。
   - **特征**：利用了 IPv4 (ihl, tos, length, flags, ttl, proto), TCP (offset, flags, window), UDP (length) 等包头特征。

实验

资源消耗少

将各方法生成的 P4 程序部署到交换机，测量实际资源消耗。
对比了 SRAM（内存）、TCAM（三态内存）、TMIX（交叉开关）、Stages（流水线阶段数）、Tables（表数量）等硬件指标。

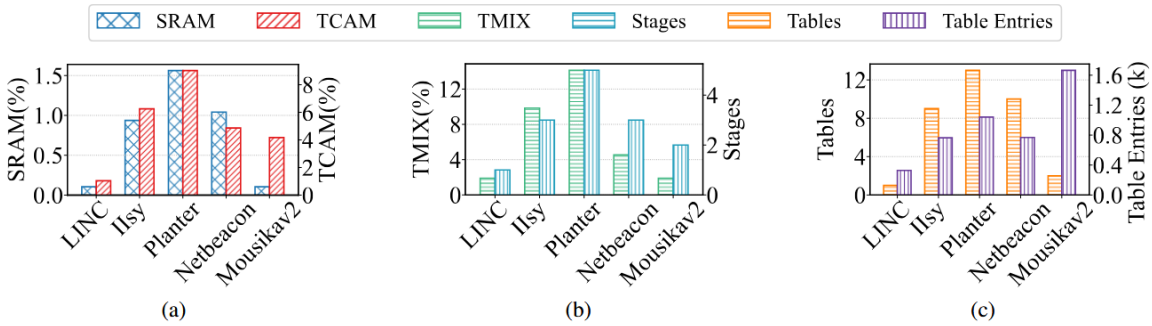

Fig. 6: The comparison of different resource usage of switches.

增量更新性能好

控制新类别的训练数据量（从 0.025 到 0.1，即 2.5% 到 10% 的数据比例）。

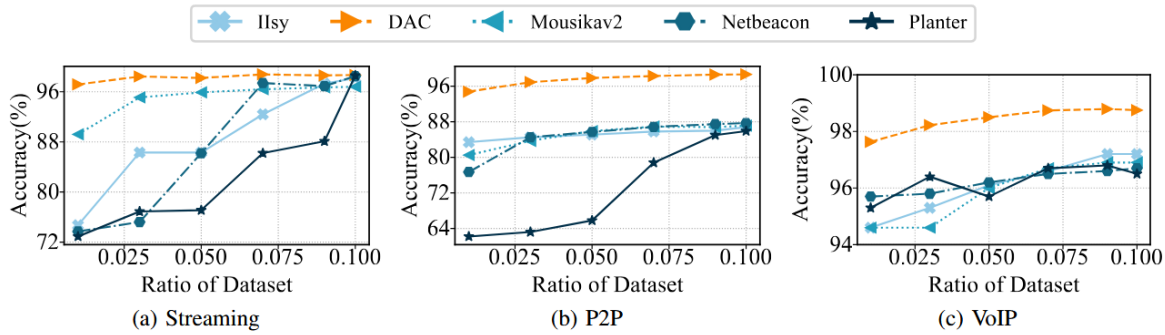

Fig. 8: Performance of updated models given different amounts of the data. We compare the accuracy of different methods during the three updates (P2P, Streaming, and VoIP respectively) by controlling the data volume.

总结

针对可编程交换机**资源受限及流量模式动态变化**的双重挑战，摒弃了传统的“大模型蒸馏到决策树”的复杂路径，转而采用一种定制化的神经网络直接学习特征与类别的稀疏映射（即将分类规则映射为交换机表项），从而生成极低资源消耗的显式匹配规则。

暂时不会研究模型资源消耗的问题

可参考模块汇总

总结了可用在未来工作中的模块

1. ***Wedjat: Detecting Sophisticated Evasion Attacks via Real-time Causal Analysis--KDD '25***

1、数据包嵌入：把加密数据包嵌入为一个代表良性概率的数值
2、因果网络构建：流内因果（相同五元组，client hello、server hello、certificate）+流间因果（相同ip对，html流、图片资源流、js脚本流）
3、基于推理的检测：packet embedding算出包的实际score，利用置信度传播算出预测score，两者差异超过阈值，则异常

最大似然估计来修剪网络
随机删边，模型性能没下降，甚至上升，则永久删除该边

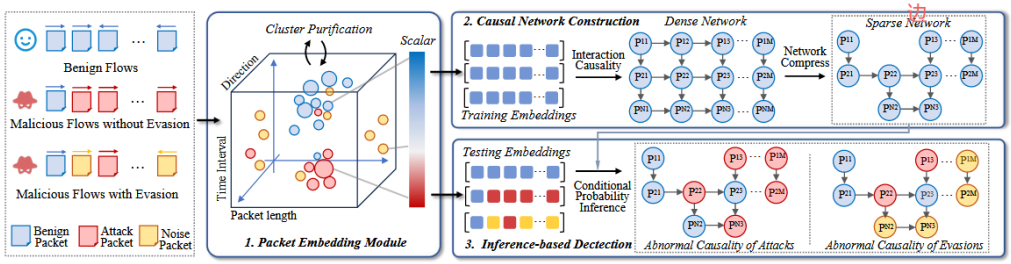

提取特征：包长、时间间隔、方向

Figure 1: The overview of Wedjat.

- **数据包嵌入模块**
  - 设计目的：将加密数据包嵌入为一个代表良性概率的数值
  - 针对的问题：数据包格式不统一、处理扰动数据、“未知”的数据包
- **因果网络构建模块**
  - 设计目的：建模相关流中数据包之间的交互模式（流内因果+流间因果），捕捉良性流量的因果依赖关系
  - 针对的问题：逃逸攻击（如插入假包、延迟发包）会破坏正常的协议交互模式和流间依赖，传统统计特征难以检测这种时序和逻辑上的违规。

2. ***Training with only 1.0 ‰ samples: Malicious traffic detection via cross-modality feature fusion--CCS '25***

$$\vec{u}_j^i = \begin{cases} 0, & \text{if} \quad j = 1, \\ 2 \cdot j + 1, & \text{elseif} \quad T \le \vec{t}_j^i - \vec{t}_{j-1}^i, \\ 2 \cdot j, & \text{else}, \end{cases} \tag{2}$$

$$\mathrm{U}_{j,p} = \begin{cases} \sin\left(p \cdot e^{-\frac{j \cdot \ln T}{H}}\right), & \text{if} \quad j \bmod 2 = 0, \\ \cos\left(p \cdot e^{-\frac{j \cdot \ln T}{H}}\right), & \text{else}, \end{cases} \tag{3}$$

$$\vec{C}^i = \mathrm{CrossAtten}(\vec{q}^i, \vec{k}^i, \vec{v}^i) = \mathrm{Softmax}\left(\frac{\vec{q}^i \circ \vec{k}^i}{\sqrt{H}}\right), \ \vec{F}^i = \vec{C}^i \circ \vec{v}^i + \vec{q}^i. \tag{13}$$

$$l_c^{(h)} = \frac{1}{B} \sum_{i=1}^{i=B-1} -\ln \left| \frac{e^{\mathrm{Sim}(\vec{q}_i, \vec{q}_{i+1})}}{e^{\mathrm{Sim}(\vec{q}_i, \vec{q}_{i+1})} + e^{\mathrm{Sim}(\vec{q}_i, \vec{q}_{i+B})}} \right|. \tag{22}$$

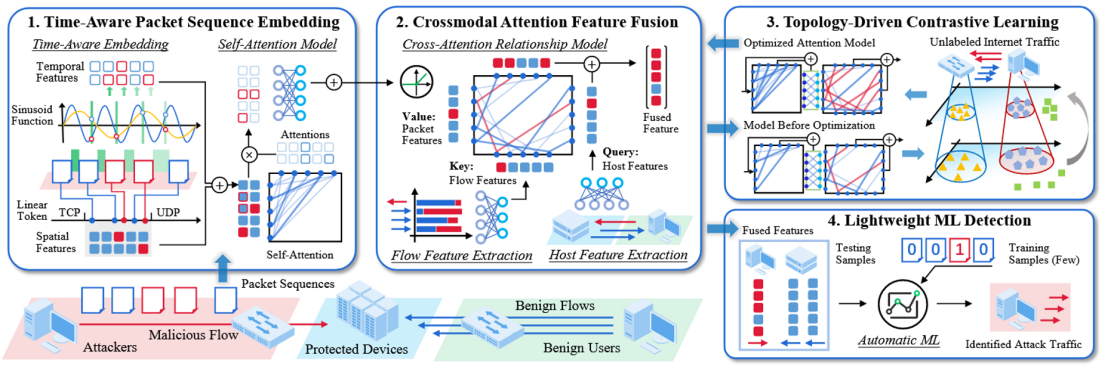

Figure 2: High-level architecture of tFusion malicious traffic detection system.

$$\vec{v}_j^i = \mathcal{I}_i.\mathrm{p} \times \mathrm{M} + \min(\vec{l}_j^i, \mathrm{M}) - 1, \tag{1}$$

- **时间感知包序列嵌入**
  - 设计目的：在包长序列中加入时间信息
  - 针对的问题：传统包长序列只关注顺序，忽略了数据包到达时间间隔这一关键测信道信息
- **跨模态注意力特征融合**
  - 设计目的：融合包级特征、流级特征、主机级特征
  - 针对的问题：单一模态特征信息量不足，导致需要大量样本才能训练好模型。通过多模态关联，可以在极少样本下挖掘出更丰富的信息。

3. ***TFE-GNN: A temporal fusion encoder using graph neural networks for fine-grained encrypted traffic classification--WWW '23***

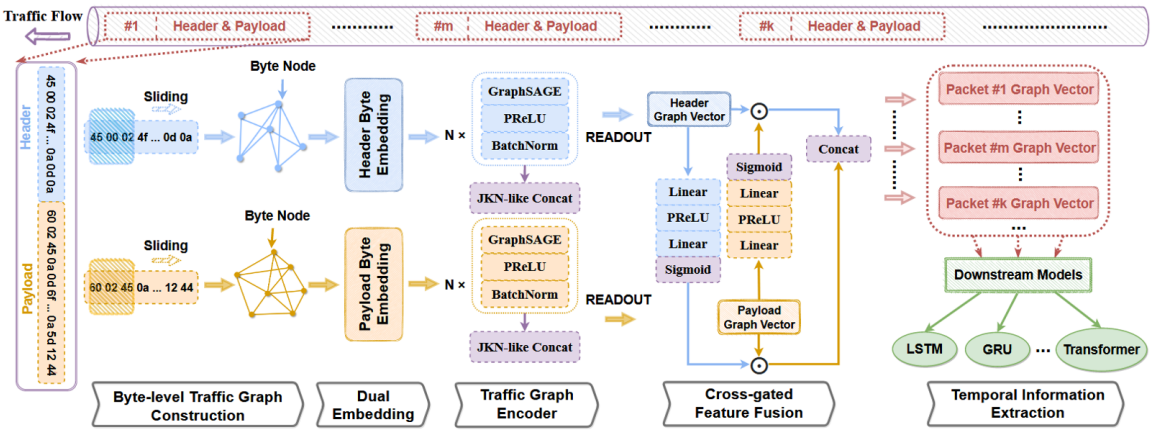

$$PMI(i,j) = \log \frac{P(i,j)}{P(i) \cdot P(j)} \qquad P(i) = \frac{\#(i)}{\text{总窗口数}} \qquad P(i,j) = \frac{\#(i,j)}{\text{总窗口数}}$$

$$a_{ij} = \begin{cases} 1, & \mathrm{PMI}(i,j) > 0 \\ 0, & \text{Otherwise} \end{cases}$$

Figure 1: TFE-GNN Model Architecture

- **字节级流量图构建**
  - 设计目的：将原始字节流（加密流量）转化为图结构，挖掘字节间的潜在关联。
  - 针对的问题：传统方法要么只用统计特征（不稳定），要么只用原始字节序列（利用率低），忽略了字节间的语义关联。
- **包头和载荷双重嵌入**
  - 设计目的：分别处理包头和载荷的语义。
  - 针对的问题：相同的字节值在包头（如协议标志）和载荷（如加密数据）中含义完全不同，混合处理会造成语义混淆。

4. ***ReTrial: Robust encrypted malicious traffic detection via discriminative relation incorporation and misleading relation correction--IEEE TIFS 2025***

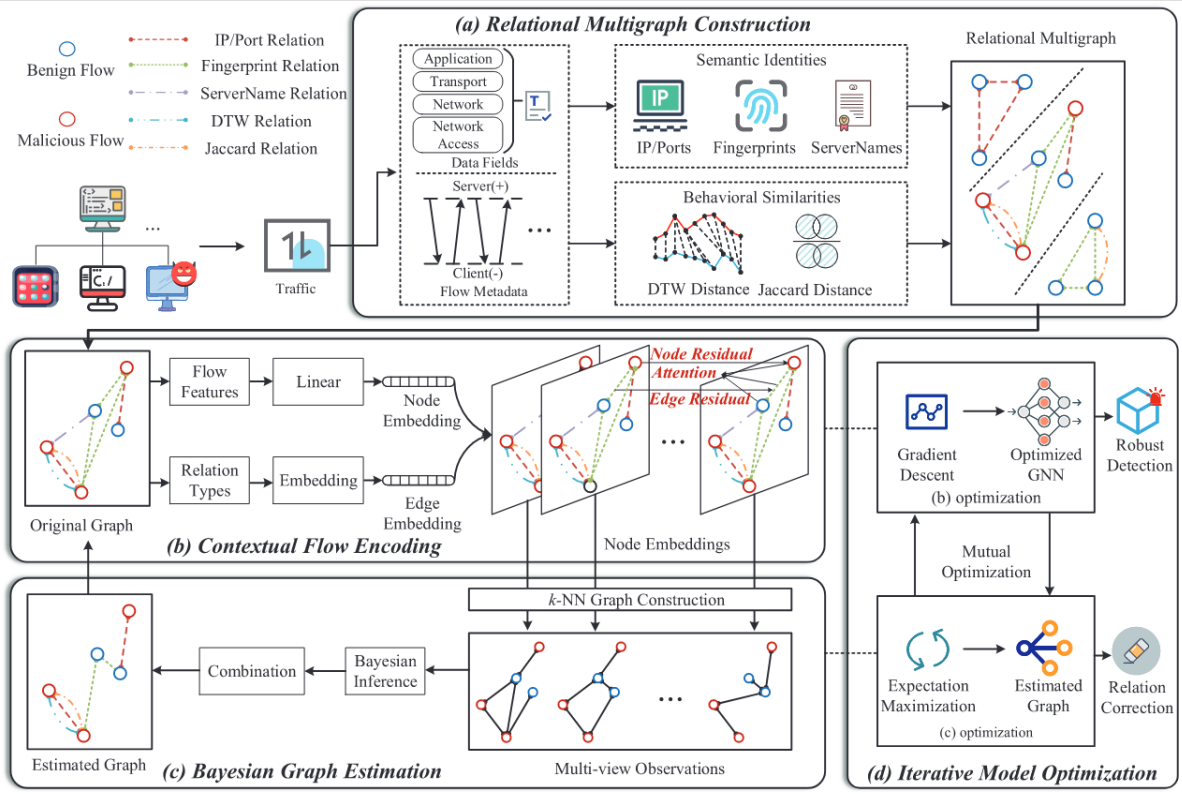

Fig. 1. The overview of our robust encrypted malicious traffic detection system ReTrial.

- **关系多重图构建**
  - 设计目的： 全面建模流之间的复杂交互关系（节点：加密流；边：相同目的ip/port、相同TLS指纹（JA3/JAS3）、相同SNI、基于DTW的包长序列相似性、基于Jaccard距离的相似性）。
  - 解决问题： 现有的图方法构图简单，且容易受到攻击者引入的虚假关系（如伪造IP）的影响。
- **上下文流编码**
  - 设计目的： 设计改进的图注意力网络，在计算注意力系数时，不仅考虑节点特征，还显式地加入“边类型”的嵌入，实现对不同关系的差异化聚合。
  - 解决问题：区分不同关系的重要性，避免被无关或恶意的邻居误导。
- **贝叶斯图估计-关键**
  - 设计目的： 推断真实的流交互图结构，修正误导性关系。
  - 解决问题： 原始构建的图中包含大量由逃逸攻击（如IP切换、指纹伪造）引入的噪声边。
  - 实现过程：
    1. 观察： 将GNN每一层的中间节点嵌入构建为k-NN图，作为“多视图观察值”。
    2. 推断： 假设存在一个潜在的“最优图”，利用贝叶斯推断，结合观察值和随机块模型（SBM）先验，计算最优图的后验概率。
- **迭代模型优化**
  - 设计目的： 联合优化GNN编码器和图结构。使用EM算法（期望最大化）
  - 解决问题： 更好的图结构能训练出更好的GNN，更好的GNN能产生更准确的观察值来修正图结构。

5. ***MIETT: Multi-instance encrypted traffic transformer for encrypted traffic classification--AAAI-25***

关注 Intra-packet relationships，如ip头和tcp头之间的关系
关注包间关系，如第1个包的第10个字节和第2个包的第10个字节有什么时序联系

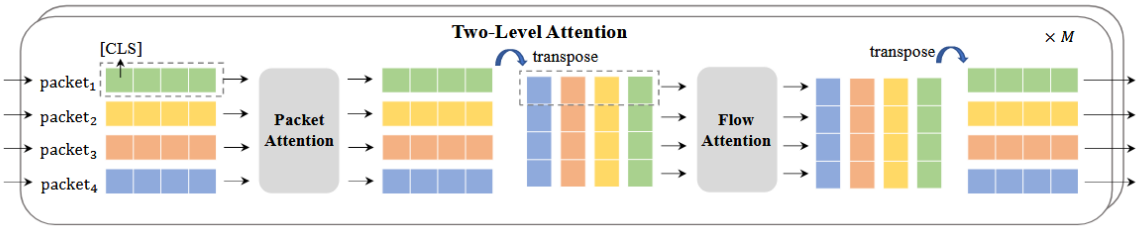

Figure 3: Overall architecture of the Multi-Instance Encrypted Traffic Transformer (MIETT). After passing through the MIETT encoder, the flow representation is processed by M Two-Level Attention (TLA) layers, each comprising a packet attention mechanism and a flow attention mechanism.

- **双层注意力层**
  - 设计目的： 分层次提取特征，兼顾包内细节和包间关系。
  - 解决问题： 降低计算复杂度，同时捕捉层次化依赖。

6. ***MetaRockETC: Adaptive encrypted traffic classification in complex network environments via time series analysis and meta-learning--IEEE TNSM 2024***

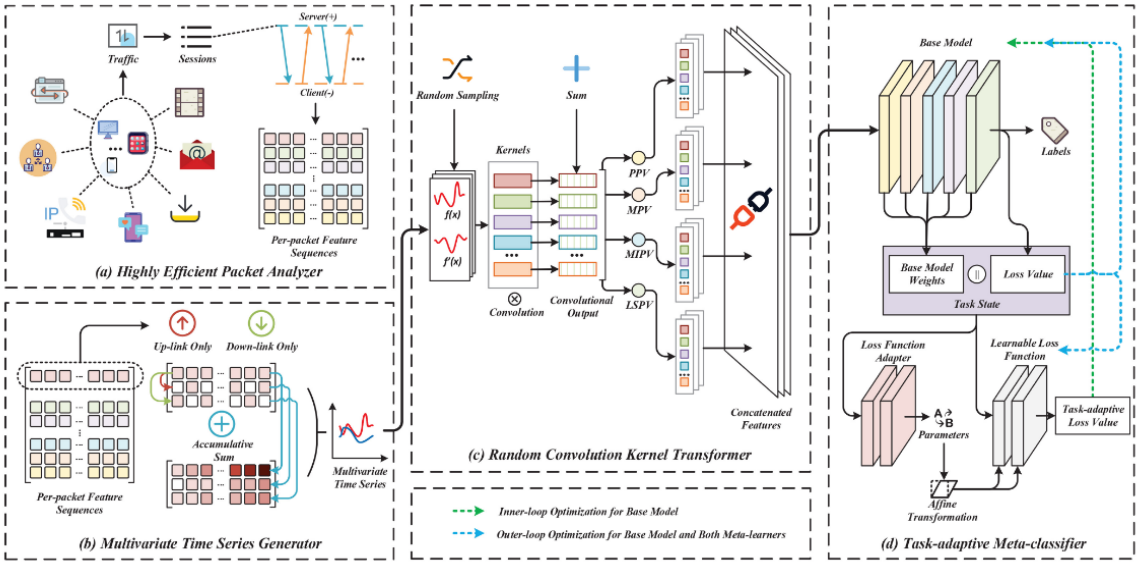

Fig. 1. The overall framework of METAROCKETC: (a) Highly Efficient Packet Analyzer; (b) Multivariate Time Series Generator; (c) Random Convolution Kernel Transformer; (d) Task-adaptive Meta-classifier.

- **随机卷积核变换器**
  - 设计目的： 极其高效地提取具有判别力的序列模式特征，生成大量随机卷积核（长度、权重、膨胀率、偏置均随机），对多元时间序列进行卷积操作。主要目的是丰富包长序列的向量维度
  - 解决问题： 深度学习训练慢、计算重。Rocket方法无需训练卷积核，速度极快。