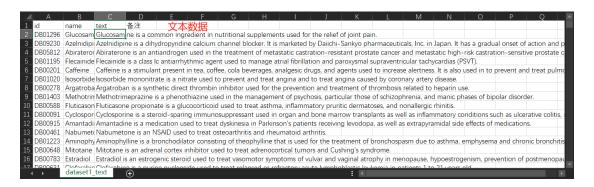
数据

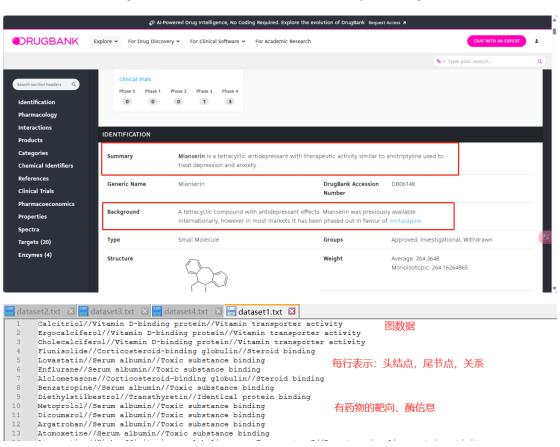
大致完成文本数据收集、对齐

进展

dataset1



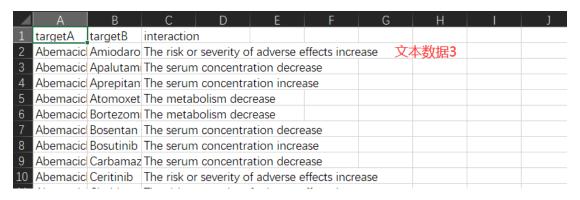
文本数据来自于 drugbank 数据库中对每个药物的 Summary 和 Background



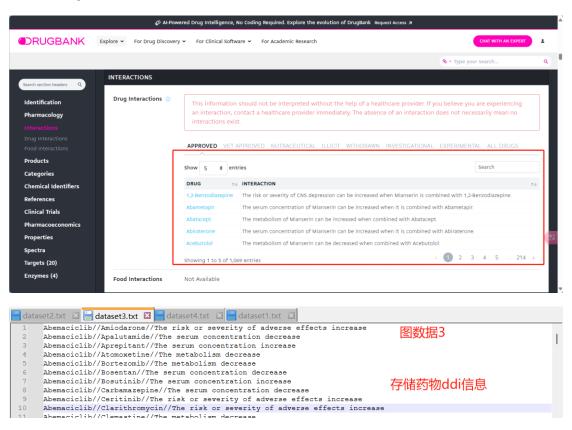
dataset2



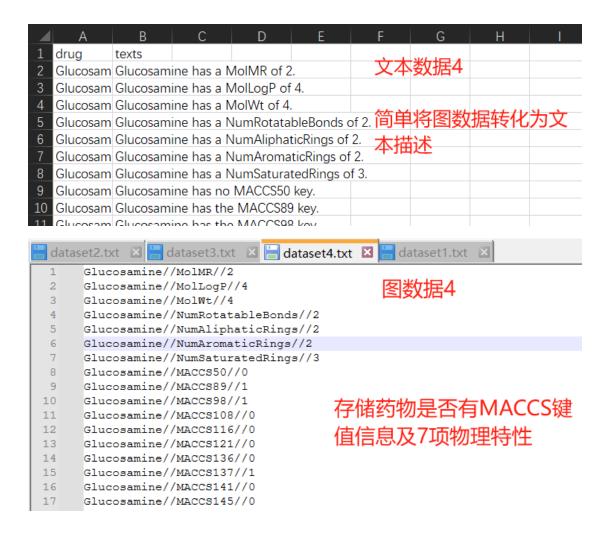
dataset3



来源于 drugbank



dataset4



问题

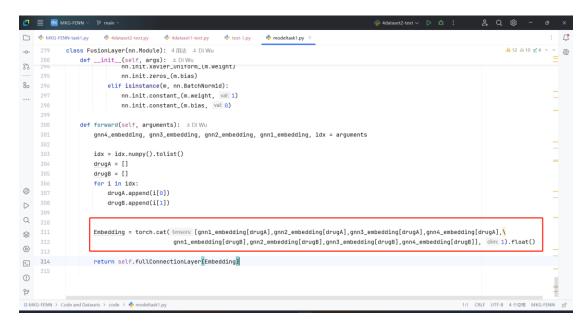
- 1、dataset2 中的文本描述可以用 CN1CCN2C(C1)C1=CC=CC=C1CC1=CC=CC21 该种方式表示,看后续实验效 果是否修改
- 2、dataset4 中还没找到关于药物 MACCS 键值的描述,所以暂时只是简单将 图数据转化成文本数据

模型、代码

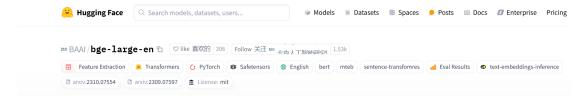
进展

代码方面还没做出修改

初步打算在代码的 Embeding 那边拼接文本数据的向量,然后在 Embeding 加一个 LLM 充分融合两种向量。



准备使用 bge-large-en 作为 LLM



问题

1、文本数据通过 LLM 输出的向量是否需要动态?

目前打算先用静态的试一试,后续试试动态。

流程

整个项目实现的流程是清楚了

下一步计划

完成文本数据向量和图数据向量的拼接、融合